

Reinforcement learning을 활용한 주식 트레이딩

First Author

Lee chan ho

Institution1 address

leechanho8511@naver.com

Abstract

주식 시장에서 투자자들은 종종 데이터 해석에 있어 편향을 가지거나, 감정적인 요인에 의해 비합리적인 투자 결정을 내리는 경우가 많습니다. 이러한 문제를 해결하기 위해, 강화학습(Reinforcement Learning, RL)을 활용한 주식 트레이딩 모델이 효과적인 대안으로 주목받고 있습니다. 본 실험은 강화학습 기반 주식 트레이딩 모델의 학습 과정과 효율성을 분석하고, 모델 성능에 영향을 미치는 주요 하이퍼파라미터의 역할을 평가하는 것을 목표로 합니다.

강화학습은 다양한 환경과의 상호작용을 통해 최적의 의사결정 전략을 학습하는 기법으로, 기존의 감정적 편향이나 비합리적인 투자 방식을 보완할 수 있는 잠재력을 가지고 있습니다. 본 실험은 강화학습 모델이 주식 트레이딩에서 어떻게 학습되고, 그 효율성이 어떤 수준인지 살펴보고, 주요 하이퍼파라미터가 학습 성능과 결과에 미치는 영향을 구체적으로 분석하였습니다.

이 실험을 통해 강화학습 모델이 주식 시장에서 합리적이고 데이터 중심적인 투자 결정을 지원할 수 있는 가능성을 확인하였으며, 하이퍼파라미터 최적화가 모델 성능을 극대화하는 데 있어 중요한 요소임을 강조하였습니다. 이러한 결과는 주식 트레이딩 분야에서 강화학습의 실질적 활용 가능성을 제고하고, 관련 실험 및 실무적 적용에 유용한 통찰을 제공합니다.

1. Introduction

주식 시장 투자 분야에서는 투자자들이 특정 데이터만 선택적으로 참고하거나 감정에 휩쓸려 투자 결정을 내리는 경우가 많습니다. 이러한 행동적 편향은 종종 비효율적이고 비합리적인 투자 결과를

초래합니다. 이러한 문제를 해결하기 위해서는 보다 폭넓은 데이터를 활용하고, 감정에 흔들리지 않는 의사결정을 지원하는 방법론을 개발하는 것이 중요합니다. 이에 따라, 감정적 요인에 영향을 받지 않는 주식 트레이딩 모델을 개발하는 것이 필요한 과제로 떠오르고 있습니다. 이 중에서도 강화학습(Reinforcement Learning, RL)은 주식 트레이딩 전략 개발에 있어 많은 주목을 받고 있는 접근법입니다. 강화학습 알고리즘은 환경과의 상호작용을 통해 최적의 의사결정 전략을 학습할 수 있는 능력을 제공하며, 이를 통해 보다 합리적이고 데이터 기반의 투자 결정을 지원할 수 있습니다. 본 실험은 주식 트레이딩에서 강화학습의 적용 가능성을 탐구하며, 이러한 모델의 학습 과정, 효율성, 그리고 학습 과정에서 하이퍼파라미터가 미치는 영향을 분석하는 것을 목표로 합니다. 본 실험을 통해 주식 트레이딩 맥락에서 강화학습 모델의 효과성을 평가하고, 성능 최적화를 위해 하이퍼파라미터 조정이 가지는 중요성을 조명함으로써 관련 실험과 실무에 유용한 통찰을 제공하고자 합니다.


1.1. 문제 정의

그러나 기존의 강화학습 기반 트레이딩 모델은 몇 가지 주요 도전 과제에 직면해 있습니다. 첫째, 학습이 완료된 이후 아무런 행동도 하지 않는 비활성화 상태에 빠지는 문제가 종종 발생합니다. 이는 탐색-활용 균형을 조정하는 E-greedy 방식에서 탐색 확률(E)이 0이 되었을 때 나타나는 현상으로, 모델이 효과적인 매수/매도 전략을 실행하지 못하게 만듭니다. 둘째, 데이터의 패턴을 제대로 학습하지 못하거나 수익률을 극대화하는 행동을 학습하는 데 어려움을 보이는 경우도 존재합니다. 셋째, 모델 성능이 학습에 사용되는 데이터 구성, 모델 설계, 보상 함수 및 하이퍼파라미터 설정에 따라 크게 달라진다는 점 역시 해결해야 할 중요한 과제입니다.

본 실험에서는 이러한 문제를 해결하기 위해 강화학습 기반 주식 트레이딩 모델의 성능에 영향을 미치는 요소들을 분석하고, 안정적으로 매수/매도 행동을


학습할 수 있는 방법론을 제안하고자 합니다. 이를 통해 강화학습 모델이 주식 시장에서 더 합리적이고 효과적인 투자 결정을 지원할 수 있는 가능성을 제시하고, 관련 실험과 실무적 적용에 기여하고자 합니다.

<랜덤 투자>



(그림1. 랜덤확률로 액션을 정해 투자한 결과)

<강화 학습 투자>



(그림2. 강화학습 모델로 투자한 결과. 모델이 단순하지만 저점에 매도하고 고점에 매도하는 것을 알 수 있다.)

2. 선행실험

강화학습은 다양한 환경에서 최적의 행동 전략을 학습하기 위해 널리 활용되고 있으며, 딥러닝과의 결합을 통해 고차원 데이터에 대한 효과적인 학습이


가능해졌습니다. 대표적인 강화학습 알고리즘으로는 DQN, A2C, A3C에 대한 주요 기여와 방법론들이 있습니다.

2.1. DQN(Deep Q-Network)

DQN은 강화학습의 대표적인 한계였던 고차원 피처에 대한 Q-map 생성의 어려움을 해결하기 위해 제안되었습니다. 기존의 Q-learning 기반 접근법은 고차원 공간에서 Q-map을 명시적으로 정의할 수 없었으나, DQN은 이를 딥러닝을 활용한 Q-map 근사를 통해 해결하였습니다. 이로써 고차원 데이터에 대해 적합한 Q-function을 학습할 수 있는 기반을 마련했습니다.

DQN은 게임 환경에서 효율적인 피처 추출 및 Q-map 근사를 위해 CNN과 Fully Connected Layer(FCC)를 결합한 구조를 제안하였습니다. CNN 레이어는 게임의 화면 정보를 입력받아, 주요 특징을 압축하여 피처 벡터를 생성합니다. FCC 구조는 CNN의 출력 피처를 입력으로 받아 Q-map을 근사합니다. 학습 방식으로 $\text{Max}Q(s',a')$ 와 $Q(s,a)$ 의 TD-오차를 최소화하는 손실 함수를 사용하여 모델을 학습합니다. 이를 통해 다양한 상태-행동 쌍에 대한 Q-value를 효율적으로 추정할 수 있습니다. DQN은 이러한 접근을 통해 고차원 데이터에서의 강화학습 문제를 성공적으로 해결하였으나, Q-value의 과대 추정 문제와 환경의 노이즈가 큰 상황에서의 학습 불안정성이라는 한계를 지니고 있습니다.

<DQN architecture>




(그림3. DQN모델 구조. 인풋으로 아타리 게임의 이미지 픽셀을 받고 DNN모델을 거쳐서 Q value를 Regression한다.)

2.2. Advantage Actor-Critic

A2C와 A3C는 DQN의 한계를 극복하기 위해 제안된 알고리즘으로, Advantage(이점) 함수 개념을 도입하여 학습 안정성을 높였습니다. Advantage 함수 $A(s, a) = Q(s, a) - V(s)$ 를 도입함으로써 상태-행동 가치 $Q(s, a)$ 가 상태 가치 $V(s)$ 보다 얼마나 더 나은지를 평가하였습니다. 이를 통해 TD-오차에서 과대 추정을 줄이고, 학습 안정성을 향상시켰습니다. A2C 동기적 학습 방식을 사용하여 Advantage 함수를 기반으로 Actor와 Critic의 성능을 개선하였습니다. 또한 A3C는 비동기적 학습 방식을 통해 여러 환경에서 독립적으로 데이터를 수집하고 병렬적으로 학습을 진행하여,

A2C보다 빠른 학습 속도를 달성하였습니다.

해당 학습방법에 따른 모델은 다음처럼 진행합니다. CNN 및 FCC 구조로는 CNN 레이어와 풀링 레이어를 통해 입력 데이터를 효율적으로 압축합니다. FCC 구조는 DQN과 유사하지만, 끝단에서 Actor와 Critic의 출력을 분리하여 각각 행동 선택과 평가를 담당합니다. 그리고 Advantage 함수 사용을 사용하여 $Q(s,a)$ 대신 $A(s,a) = r + \gamma V(s') - V(s)$ 를 사용하여 TD-오차를 계산합니다. 이를 통해 DQN 방식의 MaxQ를 대체하고, 학습 분산을 줄입니다. 또한 A3C는 여러 에이전트가 독립적으로 데이터를 수집하고 학습하며, 학습 데이터가 병렬적으로 처리됩니다. 이를 통해 기존 A2C의 동기적 수집 방식에 비해 학습 속도와 효율성을 크게 향상시켰습니다.



(그림4. actor critic model.)

2.3. 알고리즘 비교

알고리즘	주요 기여	학습 안정성	학습 속도
DQN	Q-map을 딥러닝으로 근사	상대적으로 낮음	중간
A2C	Advantage 함수 도입	높음	중간
A3C	비동기 학습 도입	높음	빠름

(표1. 알고리즘별 비교)

DQN, A2C, A3C는 각각의 기여를 통해 강화학습 알고리즘의 성능을 점진적으로 개선해왔습니다. DQN은 고차원 데이터에서의 학습 가능성을 열었고, A2C와 A3C는 Advantage 함수를 활용하여 학습 안정성과 효율성을 한층 더 발전시켰습니다. 그러나 각 알고리즘은 여전히 학습 환경 및 자원 소모 측면에서 개선의 여지가 존재하며, 이러한 한계를 해결하기 위한 추가적인 실험이 필요합니다.

3. 실험 방법론

3.1. 실험 환경 설정

본 실험에서는 강화학습 기반 주식 트레이딩 모델의 성능을 평가하기 위해 다음과 같은 환경을 구축하였습니다.

<상태>

에이전트가 입력으로 사용하는 상태 정보는 각 종목별로 제공되는 가격(Open, Low, High), 거래량(Volume) 데이터와 이를 바탕으로 계산된 20가지의 기술적 지표를 포함합니다. 이러한 지표는 주식 시장의 다양한 패턴을 반영하여 에이전트가 더 나은 의사 결정을 내릴 수 있도록 돕습니다.

<보상>

에이전트의 행동 평가를 위해 단순 수익률과 로그 수익률(Log Returns)을 보상 함수로 사용하였습니다. 기존의 단순 수익률과 비교하여 로그 수익률은 안정적이고, 복잡한 수익 평가에 적합한 지표로서 활용됩니다. 이를 통해 에이전트가 수익 극대화를 목표로 학습하도록 유도합니다.

<탐색-활용 전략 (ϵ)>

탐색-활용 균형을 조정하기 위해 ϵ -greedy 전략을 사용하였으며, ϵ 값은 학습 초기 단계에서는 1.0(완전 탐색)에서 시작하여 학습이 진행됨에 따라 0.0(완전 활용)으로 감소합니다. 이는 에이전트가 학습 초기에 다양한 행동을 시도하고, 학습이 안정화될수록 최적의 전략을 활용하도록 설계된 것입니다.

<손실 함수 (Loss Function) >

손실 함수로는 주로 Actor critic model을 두고서 비교하기 때문에 A2C에서 사용하는 Advantage 함수를 적용하였습니다. Advantage 함수는 상태-행동 가치(Q-value)와 상태 가치(V-value)의 차이를 기반으로 에이전트의 행동이 평균적인 상태 가치보다 얼마나 더 좋은지를 평가하며, 학습 안정성을 높이는 데 기여합니다.

<학습률 (Learning Rate)>

학습률(Learning Rate, LR)은 0.00001 로 설정하여, 에이전트가 학습 과정에서 이전에 학습한 정보를 유지하면서도 새로운 전략에 가중치를 부여하도록 조정하였습니다. 이는 안정적이고 점진적인 학습을 보장하기 위한 설정입니다.

<학습 반복 횟수 (Epoch) >

모델 학습은 1000부터 40000번의 Epoch를 기준으로 진행되었습니다. 초기 단계에서는 랜덤한 샘플링으로 다양한 상황을 경험하며 주식 시장에 대한 에이전트의 이해도를 높이고, 이후 학습이 안정화되면서 최적의 행동을 도출할 수 있도록 설계되었습니다.

3.2. 모델 구조 (Model Architectures)

본 실험에서는 세 가지 딥러닝 모델을 구성하여 다양한 강화학습 전략을 비교하였습니다.

CNN (Convolutional Neural Network)


CNN 아키텍처는 (컨볼루션 레이어 + 배치 정규화 + 드롭아웃) → 리니어 레이어 × 2 × 2 → 출력 레이어의 구조를 만들었습니다. 해당 구조의 특징은 CNN은 입력 데이터를 공간적으로 요약하여 주요 패턴을 학습하며, 거래 데이터의 국소적 특징을 포착하는 데 강점을 가집니다.

LSTM (Long Short-Term Memory)

LSTM 아키텍처는 (LSTM 레이어 + 배치 정규화 + 드롭아웃) → 리니어 레이어 × 2 × 2 → 출력 레이어로 구성하였습니다. LSTM은 시계열 데이터를 처리하는 데 적합하며, 과거 데이터의 장기 의존성을 학습하여 예측 성능을 강화합니다.

DNN (Deep Neural Network)

DNN의 경우는 (배치 정규화 + 리니어 레이어) × 3 × 3 → 출력 레이어를 만들었습니다. DNN은 단순하고 효율적인 구조로, 복잡한 비선형 관계를 학습하며 전반적인 성능을 제공합니다.




(그림5. 보고서결과. 최상단에 학습 방법(a3c) network(dnn) Learning rate, Discount factor, epoch, epsilon 값 기입. ENV 그래프는 주식환경 차트. agent 그래프는 에이전트가 보유한 주식수. V와 P는 초록색은 관망, 빨간색은 매수, 파란색은 매도이며 각각 행동의 가치를 표시. PV는 agent행동으로 인한 주식 수익)

3.3. 실험 결과


<ε-greedy 감소에 따른 실험>

강화학습 모델의 초기 학습 과정에서 ε-greedy 전략은 다양한 행동을 탐색하도록 설계되었습니다. ε 값이 클수록 에이전트는 랜덤으로 행동을 선택하며, 학습 초기에는 ε = 1.0 으로 설정하여 완전한 탐색을

수행하였습니다. 초반 탐색의 필요성 초반 학습 단계에서 랜덤한 행동을 선택하는 이유는 다음과 같습니다. 다양한 샘플 생성의 목적을 위해서 진행합니다. 에이전트가 각 상태(state)와 행동(action)에 대한 보상값(reward)의 다양한 사례를 생성할 수 있습니다. 이는 데이터 분포가 특정 행동으로 편향되지 않도록 방지합니다. 그리고 행동 구분하며 에이전트가 랜덤한 행동의 결과를 관찰함으로써, "하지 말아야 할 행동"과 "해야 할 행동"을 구분할 수 있는 근거를 학습합니다. 랜덤 행동은 학습이 진행됨에 따라 ε 값이 줄어들며, 에이전트는 점점 최적의 전략을 활용하는 방향으로 전환됩니다.




(그림6. 삼성전자 종목에 대해서 ε값을 점점 줄이면서 최종 학습된 결과)



(그림7 카카오 종목에 대해서 최종 학습된 결과)

기본적인 RL모델 학습방식이지만 해당 학습 방법만으로는 부족한 부분이 있습니다. 다양한 행동을 하면서 어떤 행동을 해야할지 걸러내지만 일부 결과에서는 모델이 패턴을 제대로 찾지 못하는 경우 또한 존재합니다. 모델 학습이 제대로 이루어지지 않을 경우, 에이전트의 행동은 매우 단순해지는 경향을 보인것입니다. 예를 들어, 특정 상태에서 반복적으로 동일한 행동(매수 또는 매도)만을 수행하거나, 학습되지 않은 상태에서 랜덤한 행동을 지속하는 문제가 발생했습니다.




(그림8. 현대차 종목이며 모델이 패턴을 찾지 못하고 관망의 행동만 하고 있습니다.)

단순한 행동 패턴만 학습된 모델은 복잡한 시장 환경에서 활용하기 어렵습니다. 이러한 결과는 모델 학습의 불완전성을 나타내며, 추가적인 데이터 보강 또는 하이퍼파라미터 조정이 필요함을 시사합니다.

<모델 변경에 따른 실험>


강화학습 알고리즘(A3C, A2C)과 다양한 모델 아키텍처(DNN, LSTM, CNN)를 활용하여 주식

트레이딩 전략을 학습한 결과, 각 모델의 성능 및 행동에는 다음과 같은 차이가 관찰되었습니다.



<그림9. 삼성전자종목. A3C-DNN 모델>


A3C와 DNN 조합에서는 학습 후 아무런 행동도 하지 않는 현상이 발생하거나, 모델의 행동이 지나치게 단순해지는 문제가 관찰되었습니다. DNN은 고차원 데이터의 비선형 관계를 학습할 수 있는 잠재력이 있지만, 패턴을 효율적으로 요약하거나 시계열 데이터를 처리하는 데 있어 한계가 있었습니다. 에이전트가 충분한 탐색을 통해 의미 있는 전략을 학습하지 못한 것으로 보입니다.



<그림10. 삼성전자 종목. A2C-LSTM 모델 행동 패턴>

A2C와 LSTM 조합에서는 학습 결과 아무런 행동도 하지 않는 경우가 자주 발생하였습니다. 삼성전자에서는 유의미한 패턴을 학습하지 못하였습니다. LSTM은 시계열 데이터를 처리하는 데 강점이 있으나, 특정 시장 조건에서 데이터 패턴이 명확하지 않거나 보상 구조가 적절하지 않을 경우 학습 성능이 저하되는 문제가 발생하였습니다. A2C의 동기적 학습 방식은 데이터의 불균형이나 제한된 탐색

범위에서 학습의 효율성을 낮추는 요인으로 작용했을 가능성이 있습니다.



<그림11. 카카오. A3C-CNN 모델 행동 패턴>

A3C와 CNN 조합에서는 하락장에서 매수하고 상승장에서 매도하는 기본적인 전략을 학습하였으며, 일부 상황에서는 수익을 내는 결과를 보였습니다. 그러나 이러한 전략은 충분히 정교하지 않았으며, 학습 후반부에는 아무런 행동도 하지 않는 현상이 발생하기도 했습니다. CNN은 공간적 데이터를 처리하는 데 강점을 보이지만, 장기적인 시장 변화나 복잡한 상관관계를 학습하는 데에는 한계가 있었습니다. 탐색-활용 균형(E-greedy) 조정 과정에서 학습 초기에 다양한 상황을 충분히 탐색하지 못했을 가능성이 있습니다.


모델	단순 패턴	패턴 학습 x
DNN	1	2
CNN	2	1
LSTM	1	2

<표2. 각 모델별 패턴 인식 결과>

실험 결과로는 모델 아키텍처(DNN, LSTM, CNN)의 변화만으로는 강화학습 기반 주식 트레이딩 모델의 성능을 충분히 개선하기 어렵다는 점을 보여줍니다. 특히, 학습 후반부로 갈수록 에이전트가 아무런 행동도 하지 않는 현상은 보상 함수 설계 및 학습 전략의 근본적인 한계를 드러냅니다.

<에포크 증가에 따른 실험>

본 실험에서는 에포크(Epoch)를 1,000에서 40,000까지 점진적으로 증가시키며 강화학습 모델의 학습 결과를 분석하였습니다. 학습의 진행에 따라 에이전트의 행동 패턴과 주식 시장 데이터에 대한 이해도를 평가한 결과는 다음과 같습니다.




<그림12. 삼성전자. a2c cnn모델 에포크 10000 실험 결과>

에이전트는 학습이 진행됨에 따라 매수 타이밍을 점차적으로 주가가 하락하는 지점에서 파악하는 행동 패턴을 보였습니다. 이는 에이전트가 하락장에서 매수하는 전략을 일부 학습했음을 시사하며, 기본적인 시장의 수익 창출 기회를 이해하고 있음을 나타냅니다. 반면, 매도 타이밍에 대해서는 명확한 패턴을 학습하지 못한 것으로 분석되었습니다. 에이전트는 상승장에서 매도하는 전략을 제대로 실행하지 못하거나, 비효율적인 행동을 선택하는 경향을 보였습니다. 이는 매도 행동에 대한 보상 구조의 설계가 부족하거나, 학습 과정에서 매도 타이밍을 효과적으로 학습하지 못했기 때문일 가능성이 있습니다.

<보상함수 변경에 따른 실험>

강화학습 기반 주식 트레이딩 모델에서 보상 함수는 에이전트가 매수 및 매도 행동을 학습하는 데 있어 핵심적인 역할을 합니다. 기존 모델에서는 단순 포트폴리오 수익률을 보상 함수로 사용하였으나, 이는 행동 패턴에 민감하게 반응하지 못하고 특정 행동(예시. 매수혹은 관망)에만 집중하는 경향을 보였습니다. 이를 개선하기 위해 로그 수익률(log returns)을 새로운 보상 함수로 도입하였습니다. 로그 함수는 수익률의 절대 크기보다 상대적인 변화를 더 강조합니다. 이를 통해 에이전트는 작은 변화에도 더 민감하게 반응할 수 있습니다. 또한 로그 수익률은 양의 수익과 음의 손실을 대칭적으로 처리하므로, 에이전트가 특정 행동으로 편향되지 않고 매수와 매도 간의 균형 잡힌 학습을 유도할 수 있습니다. 해당 보상함수를 적용함으로써 본

실험에서는 분산이 크게 증가한 것을 확인할 수 있었습니다.



<삼성전자 종목. a3c dnn모델에 로그 수익률 보상함수 적용>

로그 수익률을 보상 함수로 도입한 결과, 에이전트의 매수/매도 행동이 기존 보상 함수에 비해 더 민감하게 반응하며, 행동의 분산이 증가하는 긍정적인 효과를 확인할 수 있었습니다. 그러나 매수 행동에서 과도한 분산이 발생하며, 명확한 전략을 학습하지 못한 한계도 드러났습니다. 해당 실험으로부터 강화학습 기반 주식 트레이딩 모델에서 보상 구조가 행동 학습에 미치는 영향이 컸음을 알 수 있었고, 행동의 균형과 안정성을 동시에 확보할 수 있는 개선된 보상 함수 설계의 필요성이 있습니다. 특히, 매수 행동의 분산을 안정화하고 매도 행동의 민감도를 조정하는 방향으로 보상 구조를 최적화함으로써, 더욱 정교한 트레이딩 전략 구현을 해야 합니다.

4. 논의 (Discussion)

4.1. 각 실험 변수의 실질적 의미와 적용 가능성

본 실험에서 수행한 다양한 실험은 강화학습 기반 주식 트레이딩 모델의 성능에 영향을 미치는 주요 요소를 평가하는 데 중점을 두었습니다. 학습 초기 높은 ϵ 값은 에이전트가 다양한 상태와 행동을 탐색할 수 있도록 하여 초기 학습 데이터의 다양성을 확보하였습니다. 이는 강화학습 모델이 초기 단계에서 광범위한 행동 패턴을 경험하고, 장기적으로 더 나은 전략을 학습하는 데 기여했습니다. 그러나 학습 후반부로 갈수록 ϵ 값이 줄어드는 과정에서 탐색 부족으로 인해 행동 패턴이 단순화되는 경향이 나타났습니다. 이는 학습 후반에도 일정 수준의 탐색을 유지할 수 있는 전략의 필요성을 시사했습니다. 이어서 CNN, LSTM, DNN 등 다양한

모델 아키텍처를 적용한 결과, CNN은 국소적 데이터 패턴을 학습하는 데 강점을 보였고, LSTM은 시계열 데이터를 처리하는 잠재력을 확인하였으나 학습 안정성에서 한계를 보였습니다. DNN은 전반적으로 단순한 비선형 관계를 학습하는 데 적합했으나, 고차원 데이터 학습에는 효과적이지 않았습니다. 결과적으로 CNN 모델을 사용하는 것이 적합하다는 판단이 들었습니다. 마지막으로 가장 유의미한 결과로는 기존 단순 수익률 보상에서 로그 수익률로 변경함으로써, 에이전트의 행동 민감도가 증가하였으며 매수/매도 행동의 분산이 확대되는 긍정적인 결과를 확인할 수 있었습니다. 그러나 매수 행동에서 과도한 분산이 발생하며 안정적인 패턴 학습이 어려웠고, 매도 행동에서는 여전히 명확한 전략을 학습하지 못하는 한계를 보였습니다.

4.2. 강화학습 기반 주식 트레이딩 모델 개선 가능성

앞선 모델들의 문제들을 해결하기 위해서 다음과 같은 방안들을 생각해 보았습니다. 다양한 시장 상황을 반영한 데이터 증강 및 샘플링 기법을 통해 학습 데이터의 다양성을 확보해야 합니다. 또한 Discount Factor, Learning Rate, Epsilon 감소 속도 등 주요 하이퍼파라미터를 최적화하여 학습 안정성을 높이고 성능 변동성을 줄일 수 있습니다. 그리고 로그 수익률이 과한 매수행동에 큰 분산을 보였기 때문에 이를 안정화시키기 위해서 sharp rate를 보상함수로 적용하여 실험해 볼 수 있을 것이라고 생각됩니다.

5. 실험 요약 및 주요 실험 결과

본 실험은 강화학습 기반 주식 트레이딩 모델의 성능을 평가하기 위해 다양한 실험 변수를 분석하였습니다. 주요 결과는 다음과 같습니다. 로그 수익률 보상을 도입함으로써 에이전트의 행동 민감도와 분산이 증가하였으나, 매수 행동에서 과도한 분산, 매도 행동에서 민감도 부족 등의 문제가 확인되었습니다. 다음으로는 모델을 비교하였는데 CNN은 국소적 패턴 학습, LSTM은 시계열 데이터 처리, DNN은 단순한 비선형 관계 학습에 강점을 보였으나, 모두 학습 안정성 측면에서 한계를 보였습니다. 이어서 ϵ -greedy 전략은 학습 초기 다양한 행동 패턴을 학습하는 데 기여하였으나, 학습 후반부 탐색 부족으로 행동 패턴이 단순화되는 문제가 발생했습니다. 향후 이어서 해보고 싶은 것은 다양한 데이터셋에 대해 주식, 채권, 암호화폐 등 다양한 금융 자산 데이터를 활용하여 모델의 일반화 성능을 검증할 필요가 있습니다. 이런 분야에 따라서 변화를 주는 것도 있지만 실험 데이터셋을 단순히 day 차트로 학습을 시키는 것이 아니라 5분단위로 진행하여 모델에게 더 세밀한 패턴을 이해하도록 유도하는 것도 중요하다고 생각됩니다. 또한 실시간으로 데이터를 수집하고 처리할 수 있는 환경을 구축하여, 강화학습 모델의 실무적 유용성을 평가해야 합니다. 최종 가장 중요하다고 생각이 드는 것은 보상 함수 설계입니다.

매수/매도 균형을 유지하면서 행동 민감도를 효과적으로 조정할 수 있는 새로운 보상 구조를 설계해야 합니다. 그리고 모델은 결국 Q value의 값을 regression으로 예측하는 문제로 귀결됩니다. 따라서 모델을 DNN, CNN, LSTM만을 이용하는 것이 아니라 transformer 모델을 통해서 주식데이터 정보를 잘 압축해서 전달하는 방식을 적용해 보는 것도 매우 좋은 실험 방안이라고 생각합니다.

References

- [1] Playing Atari with Deep Reinforcement Learning[DQN]
- [2] Asynchronous Methods for Deep Reinforcement Learning[A2C, A3C]
- [3] A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem