

뉴스 감정분석을 활용한 한국 시장 기반 공포탐욕지수

보고서

팀: 고독한 보령 | 팀원: 권오영, 구본경, 이찬호 | 프로토타입:

<https://kospifearandgreed.vercel.app>

<목차>

1. 서론

1.1 개발 배경

1.2 한국 공포탐욕지수의 도입 필요성과 문제점 그리고 개선점

2. 공포 탐욕 지수 설명 및 벤치마크 과정

2.1 구성 요소

3. 데이터 수집 및 알고리즘 분석

3.1 데이터 수집

3.2 데이터 전처리

4. 공포탐욕지수 알고리즘 및 점수화 과정

5. K-공포 탐욕 지수 산출

5.1 데이터와 모델링 준비과정

5.2 데이터 전처리 및 증강

5.3 모델링 과정

5.4 모델 검증 과정

5.5 모델 비교과정

6. 뉴스분석결과 및 점수화

6.1 프로젝트 활용 방안

7. XAI 공포 탐욕 지수 예상 활용 방안

1. 서론

개발 배경

한국 코스피 시장은 글로벌 경제 상황과 정치적 불안정성 등 다양한 요인에 크게 영향을 받습니다. 투자자들은 복잡한 요인을 분석하기 위해 여러 지표를 활용해 증시를 분석합니다. 특히 시장 변동성에 대응하기 위해 종합적인 정보와 지표가 필요합니다. 주요 지표로는 코스피, 채권 수익률, 금리, 뉴스 등이 있으며, 이들은 한국 경제 상황을 설명하는 중요한 요소입니다. 그러나 각 지표를 개별적으로 분석하는 데에는 한계가 있습니다. 지표들이 많고, 이들 간의 관계를 설명하기 어렵기 때문에 단편적인 지표들만으로는 시장 상황을 정확히 이해하기 어렵습니다.

이를 해결하기 위해 다양한 지표를 종합한 '공포 탐욕 지수(Fear and Greed Index)'를 제안합니다. 미국 CNN에서 발표한 이 지수는 투자자들이 시장 심리를 이해하는 데 도움을 주는 종합적인 지표로, 공포와 탐욕의 수준을 수치화하여 시장 분위기를 파악할 수 있게 합니다. 이를 통해 투자자들은 더 나은 의사 결정을 할 수 있으며, 급변하는 시장 상황에 효과적으로 대응할 수 있습니다.

미국 공포탐욕 지수는 7가지 지표로 구성됩니다. S&P500 지수 대비 125일 평균(시장 모멘텀), NYSE 거래소의 52주 평균 최고가(시장 모멘텀), McClellan 거래량 총합 지수(주가 폭), 5-day average put/call ratio(풋&콜 옵션), VIX와 그 50일 이동 평균(시장 변동성), 채권 주식 수익률 20일 평균 차이, 정크본드와 안전자산 차이로 구성됩니다. 이 지수는 시장의 과매수 및 과매도 상태를 파악하는 데 유용하며, 투자자들이 신뢰성 있는 정보를 바탕으로 투자 결정을 내릴 수 있도록 돕습니다.

이를 통해 투자자들은 시장의 극단적인 상황에서 리스크를 효과적으로 관리할 수 있습니다. 공포 탐욕 지수는 시장 심리를 반영하여, 투자자들이 변동성 높은 시장에서도 안정적인 전략을 세우는 데 중요한 역할을 합니다. 그러나 정량적 데이터만으로는 투자자들의 리스크 심리를 충분히 파악하기 어려운 단점이 있습니다. 또한, CNN의 공포 탐욕 지수는 미국 시장을 기반으로 개발된 지표로, 한국 시장에 그대로 적용하기에는 한계가 있습니다. 이 외에도 지수의 구성 요소가 미국 시장에 특화되어 있어 다른 시장에서는 동일한 효과를 기대하기 어렵습니다.


이러한 한계점을 인식하고, 한국 시장에 맞춘 별도의 보완 지표를 활용하거나, 공포 탐욕 지수를 참고 자료로 사용하면서도 한국 시장 특성을 반영한 추가 분석이 필요하다는 점을 발견하였습니다.

코스피 공포 & 탐욕 지수

CNN FEAR & GREED INDEX를 코스피 시장에 맞게 재구성하였습니다



Previous close	61.8 - 탐욕
1 week ago	73.5 - 탐욕
1 month ago	62.7 - 탐욕
1 year ago	69.8 - 탐욕



(<https://kospi-fear-greed-index.co.kr>)

한국 공포탐욕지수의 도입 필요성과 문제점 그리고 개선점

한국에서도 '코스피 공포탐욕 지수'를 만들어 시장 상황을 설명하려는 시도가 있었지만, 실제 활용은 적었습니다. 저희는 이를 이용한다면 투자자들이 현명한 판단을 할 수 있을 것이라고 생각해 '공포탐욕 지수'의 상용화를 고민하게 되었습니다. 금융 지표들은 각각 독

립적으로 존재하며, 여러 데이터를 합치면 오히려 해석이 어려워지는 등의 문제점이 있었습니다. 한국 투자자들은 단순한 숫자가 아닌 시장의 복잡한 심리를 종합적으로 분석한 새로운 인사이트를 필요로 했습니다. 이에 따라 공포탐욕 지수를 도입해 효과적으로 활용할 수 있도록 했습니다. 또한 수많은 뉴스 기사나 영상 분석이 개인에게겐 버거웠습니다. 하지만 최근 금융 분석 AI에서는 텍스트 데이터를 기반으로 감정분석을 하여 정성적 데이터를 정량적 데이터로 변환합니다. LLM을 이용한 뉴스 헤드라인 분석은 주가 예측에도 많이 사용됩니다. 이러한 트렌드를 반영하여 지표 분석 전략을 마련했습니다. 기본적으로 기존 CNN의 7가지 지표를 벤치마킹하여 코스피, 코스피200선물, 채권 등에 적용해 데이터를 수집했습니다. ~~이를 위해 naver API, 셀레니움 등을 사용했습니다. BERT 모델과 네이버 하퍼클로바X 스튜디오를 통해 뉴스 기사를 분석하여 투자자 심리를 반영하고, 감정 분석을 통해 정성적 데이터를 정량화했습니다.~~ 해당 방법으로 우리는 핵심적인 지표들만 모아 단순하고 해석력 높은 지표를 제공하여 한국 시장에 대한 이해도를 높였습니다. 결론적으로 한국형 공포 탐욕 지수는 투자자들이 시장의 복잡한 심리를 종합적으로 분석한 새로운 인사이트를 제공하며, AI 기반의 감정 분석을 통해 금융 분석의 부담을 감소시킵니다. 이를 통해 투자자들은 한국 증시 움직임의 이유를 보다 잘 이해하고 활용할 수 있으며 단기적 투자 전략뿐만 아니라 장기적 투자 계획에도 중요한 역할을 할 것 입니다. 최종 목표는 CNN 공포탐욕지수의 방식과 동일하게 지수를 계산하고, AI 모델을 통해 뉴스를 분석해 정량적 데이터로 변환한 데이터를 결합해 보다 정확한 지수를 개발하는 것입니다.

2. 공포 탐욕 지수 설명 및 벤치마크 과정

코스피 공포 탐욕 지수


코스피 공포 탐욕 지수(KOSPI Fear and Greed Index)는 CNN 공포 탐욕 지수를 벤치마킹하여 한국 시장에 맞게 조정된 지표입니다. 한국 시장의 특성을 반영한 이 지표는 기존의 7가지 지표와 뉴스 지표를 합쳐 투자자들의 심리를 정확하게 분석하고, 시장의 극단적인 상황에서도 효과적인 리스크 관리를 가능하게 합니다.

구성 요소

1. 정크본드의 수요 (Junk Bond Demand)

- 정크본드는 투자 등급이 낮아 위험도가 높은 채권입니다.
- 정크본드와 투자 등급 채권 간의 수익률 차이를 분석합니다.
- 정크본드의 수익률이 낮아지고 가격이 상승하면 투자자들이 더 높은 위험을 감수하고 있다는 의미로 탐욕 상태를 나타냅니다.

한국 정크본드 스프레드 (Junk Bond Spread) - 최근 1년



2. 주가 모멘텀 (Stock Price Momentum)

- KOSPI 지수와 125일 이동평균선을 비교하여 시장의 모멘텀을 분석합니다.
- 모멘텀 증가 시 탐욕(Greed), 모멘텀 감소 시 공포로 해석합니다.


KOSPI 지수 모멘텀



3. 주가 강도 (Stock Price Strength)

- KOSPI의 52주 신고가와 신저가를 맞추는 주식의 수를 비교합니다.
- 52주 신고가 주식이 많을수록 탐욕, 신저가 주식이 많을수록 공포를 나타냅니다.

52주 신고가 비율 (최근 1년)



4. 주가폭 (Stock Price Breadth)

- 상승 종목 대비 하락 종목의 거래량을 분석합니다.
- McClellan Volume Summation Index라는 지표를 사용합니다.
- 상승 종목 거래량이 많을수록 탐욕, 하락 종목 거래량이 많을수록 공포를 나타냅니다.


McClellan Volume Summation Index (최근 1년)



5. 풋 & 콜 옵션 비율 (Put and Call Options)

- 한국 옵션 시장에서 풋 옵션과 콜 옵션의 거래량 비율을 분석합니다.
- 풋 옵션 거래량이 많으면 공포, 콜 옵션 거래량이 많으면 탐욕을 나타냅니다.


KOSPI 풋/콜 Ratio (최근 1년)



6. 시장 변동성 (Market Volatility)

- VIX 지수를 통해 시장의 변동성을 측정합니다.
- VIX 지수는 KOSPI 옵션의 30일간 예상 변동성을 나타냅니다.
- 변동성이 증가하면 공포(Fear), 변동성이 감소하면 탐욕을 나타냅니다.


KOSPI VIX 및 50일 이동평균 (최근 1년)



7. 안전자산의 수요 (Safe Haven Demand)

- 주식과 국채의 수익률 차이를 분석하여 안전자산에 대한 수요를 평가합니다.
- 정크 본드 수익률이 높으면 정크 본드 가격이 하락하므로, 수요가 감소합니다. 해당 신호는 안전자산에 사람들이 몰리고 있다는 뜻으로 해석되어 지수의 상승은 공포(fear), 반대는 탐욕(Greedy)으로 해석합니다.

KOSPI 안전투자차수요 (최근 1년)



8. 언론 기사 (News Articles)

- 코스피 공포 탐욕지수에서 새롭게 편입된 지표입니다.
- LLM을 이용하여 뉴스 기사를 분석하고, 시장에 미치는 영향을 평가합니다.
- 뉴스 데이터의 감정 분석 결과에 따라 공포(Fear)와 탐욕(Greed)을 평가합니다.

“메가 캐리어” 폭탄 대한항공... ‘몸집’ 키우고 ‘군살’ 뺀다	대한항공, 美 보잉과 항공기 구매 MOU 체결 2024년까지 최첨단 친환경 항공기 2	1	https://economist.com
우리은행, IT서비스관리 국제표준 인증 획득	[서울=뉴시스] 이창필 기자 = 우리은행은 IT서비스관리(ITSM) 부문 국제표준인 ‘I	1	https://www.new
한진, 국내 최대 336MW 대용량 에너지저장장치 건설	밀양 부북변전소서 최초 가압 전력공급 불안정성 해소 기대 한국전력은 지난 19일	1	http://www.segye
금융혁신위원회, 재원을 재생에너지 바이오소재 등 친환경 사업 강화	금융혁신위원회는 식음료학 업계의 성장 둔화에 따라 돌파 전략을 모색하고 있다	1	https://www.mk.co
캐리비안, ‘불안’이 ‘바람’이 메타버스에서 만난다... 디즈니와 계약	[이 기사에 나온 스타트업에 대한 보다 다양한 기업정보는 유니콘팩토리 빅데이터	1	http://news.mt.co
좋은 사람들, 25일 주식 거래 재개... 재무 구조 개선 노력 결실	인더웨어 브랜드 ‘좋은 사람들’이 7월 25일 한국 거래소에서 주식 거래를 재개했다.	1	https://biz.chosun
신보 ‘금융교육 이자’ 대국민 서비스 선정 - 글로벌이코노믹	신용보증기금은 기획재정부 주관 ‘24년 하반기 공공기관 대국민 제강형 서비스 개	1	https://www.g-en
“이번엔 진짜?”... 삼성전자, ‘HBM 통과’ 기대감 다시 꿈틀	엔비디아 품질검증 통과 임박설 삼성 측 “확인할 수 없다” 임장 통과시 경쟁력 확보	1	http://www.news
한화생명, ‘한국산업의 서비스품질지수’ 생령보험 부문 15년 연속 1	(서울=뉴시스) 정도민 기자 = 한화생명이 한국능률협회컨설팅 주관 ‘2024 한국산업	1	https://www.new
[이시혜의 뷰]기아차를 기대해	[이데일리TV 이지혜 기자]현대차(005380)가 기아(000270)를 인수한 지 25년이	1	http://www.edaily
“핀란드 가수부터 케냐 공무원까지”...성표, ‘우리들’ 공간’ 찾는 외국 K-푸드 위상 높아지면서 방문 희망 단체 크게 늘어 (서울=뉴시스)	이창진 기자 = 성	1	https://www.new
프랙시스, 비즈니스 투자원금 3배 최수	“투자→블트론→밸류업→회사” 순환 4호 블라딘드 자금 모집 탄력 기대 사모펀드(I	1	https://news.here
“혁신 스타트업 최대 3억 지원”... CJ 프론티어 램스 47기 시동	8월 4일까지 참가기업 모집 CJ제일제당이 유망 스타트업에 대한 지원 체계를 강화	1	http://www.fnnnews
텔레그램, 캄보디아 IT 인재 육성 지속	캄보디아 HRD센터 12번째 졸업식 성료 졸업 후 글로벌 IT 기업 및 금융기관 취업	1	http://www.segye
예정산업, ‘2024 올해의 녹색상품’ 2개 제품 선정	생활유통기업 예정산업은 한국녹색구매네트워크 주관하는 ‘2024 올해의 녹색상	1	http://www.edaily
오브렌, 35억원 규모 모니모 완결 구축 계약	[이데일리 박순영 기자] 오브렌(417860)은 삼성SDS와 35억1195만원 규모의 상	2	https://www.edaily
웅진씽크빅, 동물 시장 진출... 국내 최대 키즈 플랫폼 자판기와 MOI 웅진씽크빅과 함께 최대 방문교사를 보유한 키즈 플랫폼 자판기가 완성형 동물-교	웅진씽크빅과 함께 최대 방문교사를 보유한 키즈 플랫폼 자판기가 완성형 동물-교	2	https://news.here
CJ제일제당, 파리에 한국식 전통시장 연다	코리아하우스 ‘K-스트리트 푸드’ 일려 시작행사 통해 현지 입점 기회 모색도 (메트로	2	https://www.new
한화연진 2분기 영업이익 186억...전년비 436% “경종”	매출 2865억원으로 51.5% 늘어 (서울=뉴시스) 최동현 기자 = 한화연진(082740)	2	https://www.new
삼성물산, 루마니아 소형모듈원전 기본설계 계약 수주	글로벌 엔지니어링 3개사와 합작으로 프로젝트 수행 [이데일리 한재욱 기자] 삼성물	2	http://www.edaily

3. 데이터 수집 알고리즘 및 데이터 분석

3.1 데이터 수집

데이터 수집 과정에서는 다양한 출처에서 필요한 데이터를 자동으로 가져오는 알고리즘을 사용합니다. 이는 주로 API를 통해 이루어지며, 크롤링 기술도 사용됩니다. 주요 데이터 출처는 다음과 같습니다:

- **공공 데이터 포털**: 금융위원회 및 KRX의 지수 시세 정보를 제공합니다.
- **NICE 신용평가**: 금리 및 스프레드 데이터를 제공합니다.
- **NAVER NEWS API**: 뉴스 기사 원문 데이터를 수집합니다.
- **빅카인즈**: 키워드와 주간 이슈를 수집합니다.
- **KRX 지표 데이터**: 한국 거래소에서 제공하는 지표 데이터를 수집합니다.

3.2 데이터 전처리

수집된 데이터는 분석 전에 전처리 과정을 거쳐야 합니다. 이 과정에서는 다음과 같은 작업을 수행합니다:

7가지 지표

- **데이터 정제**: 결측값 처리, 중복 데이터 제거
- **형식 변환**: 데이터 형식을 통일하여 분석에 적합하게 변환

- 이동평균 계산: 이동평균선과 같은 지표 계산을 위한 데이터 변환
- z-index score 측정: 이동평균선에서 떨어진 정도를 비교

뉴스 데이터 지표

- 뉴스 데이터 키워드 수집
- NAVER NEWS API를 통한 URL 수집
- URL을 통해 원문 수집
- 데이터 증강 작업: Naver Hyper Clova X를 통해 학습 데이터 비율 불균형 해소

4. 공포탐욕지수 알고리즘 및 점수화 과정

1. 각각 전처리 된 데이터를 당일 이전 1년 데이터를 포함하여 정규 분포를 이용해 z-score 를 구합니다

- $P(-2.25 < Z < 2.25) = 0.9892$


2. 각 점수를 낸 것을 바탕으로 공포 탐욕 grade를 만들어 종합하여 만듭니다.

- 예외 값은 각각 0점 12.5점으로 최고점 부여

3. 해당 지표들에 대해서 총 8가지 지표이기 때문에 12.5점으로 점수화하여 총 100점으로 표현하였고 구간별로 극도 공포, 공포, 중립, 탐욕, 극도 탐욕으로 구간을 구분하였습니다.

0-25 : 극도의 공포 25-45 : 공포 45-55 : 중립

55-75 : 탐욕 75-100 : 극도의 탐욕




5. 뉴스 분석 모델 비교 과정 및 모델 알고리즘 설명

5.1 데이터와 모델링 준비과정

데이터 수집과정에 대해서 설명하면 두가지 방식을 사용하였습니다. 코스피 125일 데이터 - 야후 파이낸스 api, MSI, 52주 신고가, 코스피200P/C ratio, 채권 - KRX, VIX - investing.com에서 가져왔습니다. 이중에서 뉴스 데이터의 경우 빅카인즈와 vaiv, 네이버 뉴스, 캐글(미국 기사 라벨링 데이터)를 가져왔습니다. 이중에서 뉴스데이터의 경우 셀레니움 동적 크롤링 방식을 사용하여 모델을 가져왔습니다.

사용한 뉴스 분석 모델은 두가지가 있습니다. NAVER HYPER CLOVAR X에서 제공하는 STUDIO 환경에서 모델을 튜닝하는 방식과 BERT모델에서 사용한 모델을 두가지를 사용하였습니다. 해당 모델의 학습 속도를 개선하기 위해서 Colab 환경에서 GPU T4를 사용하여 모델을 개발하였습니다.

5.2 데이터 전처리 및 증강




캐글에서 수집한 미국 석학들의 데이터를 기반으로 데이터를 수집하였고 추후에 육안 검사를 통해서 약 1600개 정도의 기사 검출을 완료하였습니다. 그 이후에 한국 뉴스 기사 해석 능력에 대한 문제가 발생하여 300개의 라벨링된 한국 뉴스 기사 라벨데이터를 수집하였습니다. 하지만 모델 학습에 있어서 데이터 개수가 부족하다는 생각을 하였고, HyperCLOVA Data Augmentation을 적용하여 총 1만개의 데이터를 증강시켜 모델 학습을 진행하였습니다. 이후 모든 1만개의 데이터에 대해서 전처리(중복제거, 특수문자 제거, 라벨링)작업을 진행하여 모델링 시작전 데이터 수집과정을 마쳤습니다.

5.3 모델링 과정

모델링 과정에서 가장 중요한 것은 문장을 토큰화하고 토큰화한 단어를 임베딩하는 것이 매우 중요합니다. 다음은 네이버와 BERT모델에서 적용한 단어 임베딩 과정의 차이에 대해서 설명드리겠습니다.

<Naver studio>



비즈니스에 최적화된 하이퍼스케일 AI 개발도구

CLOVA Studio는 기업이 보유한 대량의 전문 데이터셋을 HyperCLOVA X 언어 모델과 결합해 AI 기반의 특화된 서비스를 손쉽게 만들 수 있는 개발 도구입니다. 비즈니스 목적에 최적화된 CLOVA Studio를 통해 기업의 생산성을 향상하고 경쟁력을 강화할 수 있으며, 기업이 겪고 있는 다양하고 어려운 여러 문제들을 해결할 수 있습니다.

우측 사진에서 보이는 것과같이 Naver HyperCLOVA 익스플로러에서 NLP모델의 학습을 지원하는 여러 기능들을 파이프라인으로 지원해주고 있습니다. 따라서 저희는 이 Naver studio에서 모델링을 할때는 Data Augmentation을 적용해주고 이후 과정들은 파이프 라인과정을 따라서 진행하였습니다. 전체적인 Naver HyperCLOVA에서 제공하는 모델 파이프 라인 과정은 데이터 수집 및 전처리(naver API와 셀레니움 동적 크롤링) 진행, 텍스트 임베딩(의미와 문맥을 파악하여 텍스트 임베딩 진행 후 텍스트 수치화), 모델 학습 및 튜닝이 있습니다. 모델 학습 및 튜닝에서는 감독 학습(Supervised Fine-tuning, SFT)와 강화 학습(Reinforcement Learning from Human Feedback, RLHF)방식이 존재합니다. 저희는 라벨링이 완료된 데이터에 대해서 감정분석 모델을 개발하기 때문에 따로 인간의 의견이 개입된 강화학습이 아닌 감독 학습을 진행하여 모델링을 완료하였습니다.

<BERT MODEL>

BERT 모델로부터 진행한 과정은 앞서 설명한 네이버에서 제공된 파이프 라인을 이용하는 것과 달리 하나하나 데이터 수집, 전처리, 학습 검증 데이터셋 분리, 모델 선택의 과정을 진행해야 했습니다. 그 과정은 다음과 같습니다.

[torch]

pytorch에서 모델 학습을 적용하여 torch환경에 맞는 데이터 분리와 F1지수 검증에 대한 함수들을 사용하였습니다.

[transformer]

데이터 임베딩을 위해서 BertTokenizer를 사용하였고 이후에 감정분석을 위한 BertForSequenceClassification 모델과 optimzer로써 AdamW, BertConfig 등등을 필요 함수로 import 하였습니다.

[sklearn]

해당 라이브러리에서는 train test set을 구분하는 함수를 사용하였습니다.

[기타 라이브러리]

pandas, numpy: csv파일을 불러와 cloadb환경에서 우수하게 데이터 처리를 가능케하는 라이브러리입니다.

matplotlib: 데이터 처리과정에서 필요한 그래프를 해당 라이브러리를 이용하여 표현하였습니다.

기타: random, time, datetime함수들은 시간처리나 혹은 난수 생성에 필요한 라이브러리입니다.

<데이터 임베딩>

BertToknizer에서는 사전 한국어 훈련이 된 'klue/bert-base'를 사용하였습니다. 이후 전체 문장 토큰 길이와 배치 사이즈를 설정하여 임베딩에 필요한 사전 변수들을 설정한 후 각각을 input data와 어텐션 마스크, 라벨 데이터로 분류를 합니다.

최종적으로 해당 영역에 코드에서는 pytorch환경에서 모델을 학습 시키기 위해서 데이터 형태를 만들어주면서 학습을 위한 데이터 파이프라이닝을 최종적으로 마칩니다.

```
import torch

from transformers import BertTokenizer
from transformers import BertForSequenceClassification, AdamW, BertConfig
from transformers import get_linear_schedule_with_warmup
from torch.utils.data import TensorDataset, DataLoader, RandomSampler, SequentialSampler
from keras.preprocessing.sequence import pad_sequences
from sklearn.model_selection import train_test_split

import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import random
import time
import datetime

#GPT
from torch.utils.data import DataLoader, TensorDataset, random_split
import torch.nn.functional as F
```

```
# BERT 토크나이저 로드
max_seq_len = 128
tokenizer = BertTokenizer.from_pretrained('klue/bert-base')

input_data = combine_info_extended
inputs = tokenizer(list(input_data['Text']), return_tensors='tf', padding=True, truncation=True, max_length=max_seq_len)
input_ids = inputs['input_ids'].numpy()
attention_mask = inputs['attention_mask'].numpy()
labels = input_data['Completion'].values

# numpy 배열을 PyTorch 텐서로 변환
input_ids = torch.tensor(input_ids)
attention_mask = torch.tensor(attention_mask)
labels = torch.tensor(labels)

# train/validation split
train_input_ids, val_input_ids, train_attention_mask, val_attention_mask, train_y, val_y = train_test_split(
    input_ids, attention_mask, labels, test_size=0.2, random_state=42)

# TensorDataset 생성
train_data = TensorDataset(train_input_ids, train_attention_mask, train_y)
val_data = TensorDataset(val_input_ids, val_attention_mask, val_y)

# DataLoader 생성
BATCH_SIZE = 32
train_sampler = RandomSampler(train_data)
train_dataloader = DataLoader(train_data, sampler=train_sampler, batch_size=BATCH_SIZE)

validation_sampler = SequentialSampler(val_data)
validation_dataloader = DataLoader(val_data, sampler=validation_sampler, batch_size=BATCH_SIZE)
```

<GPU T4>

단순 CPU사용으로 모델을 학습할 경우 많은 양의 데이터 처리에 문제가 발생하여 우측과 같이 모델 학습을 위해 GPU T4 을 사용하여 학습을 진행하였습니다. 매우 빠른속도의 모델 학습을 완료 할 수 있다는 장점이 있습니다.

cuda:0
Tue Jul 30 09:37:34 2024

NVIDIA-SMI 535.104.05			Driver Version: 535.104.05		CUDA Version: 12.2		
GPU	Name	Perf	Persistence-M	Bus-Id	Disp.A	Volatile	Uncorr. ECC
Fan	Temp		Pwr:Usage/Cap		Memory-Usage	GPU-Util	Compute M.
							MIG M.
0	Tesla T4	P0	Off	00000000:00:04:0	Off	0	0
N/A	76C		29W / 70W	3483MiB / 15360MiB		0%	Default
							N/A

Processes:

GPU	GI	CI	PID	Type	Process name	GPU Memory
	ID	ID				Usage

<train 과정>

해당 우측 코드를 통해서 trian 데이터를 가져오면서 GPU에 전달 하여 모델이 학습을 진행할 수 있고, 이후 실제 라벨과 비교하면서 예측과의 차이를 계산하면서 해당 값을 이용하여 파라미터를 계속해서 수정합니다.

```
# 데이터로더에서 배치만큼 반복하여 가져옴
for step, batch in enumerate(train_dataloader):
    # 경과 정보 표시
    if step % 500 == 0 and not step == 0:
        elapsed = format_time(time.time() - t0)
        print(' Batch (>5,) of (>5,). Elapsed: ({}).'.format(step, len(train_dataloader), elapsed))

    # 배치를 GPU에 넣음
    batch = tuple(t.to(device) for t in batch)

    # 배치에서 데이터 추출
    b_input_ids, b_input_mask, b_labels = batch

    # Forward 수행
    outputs = model(b_input_ids,
                    token_type_ids=None,
                    attention_mask=b_input_mask)

    logits = outputs.logits

    #ロス 구함
    loss = loss_fn(logits, b_labels)

    # 총로스 계산
    total_loss += loss.item()

    # Backward 수행으로 그래디언트 계산
    loss.backward()

    # 그래디언트 클러닝
    torch.nn.utils.clip_grad_norm_(model.parameters(), 1.0)

    # 그래디언트를 통해 가중치 파라미터 업데이트
    optimizer.step()
```

<vailidation 과정>

train과 거의 동일하게 진행하는데 8:2이 비율로 나눈 데이터중 2 에 해당되는 데이터이고 이 과정으로부터 모델의 학습이 이루어 지는 지 확인합니다.

```
# 그래디언트 계산 비활성화
with torch.no_grad():
    for batch in validation_dataloader:
        batch = tuple(t.to(device) for t in batch)
        b_input_ids, b_input_mask, b_labels = batch

        outputs = model(b_input_ids, token_type_ids=None, attention_mask=b_input_mask)
        logits = outputs.logits

        # 예측값 계산
        logits = logits.detach().cpu().numpy()
        predictions.append(logits)

        # 실제 라벨 저장
        label_ids = b_labels.to('cpu').numpy()
        true_labels.append(label_ids)
```

5.4 모델 검증 과정

모델검증 지표로는 F1 score, ROC AUC, 정밀도와 재현율, 혼동 행렬을 통해서 모델을 검증하였습니다.

ROC AUC:

정확도와 재현율: 정확도와 재현율을 확인하는 것이 매우 중요합니다. 정확도의 경우 모델이 예측한것중에서 실제로 맞는 정답이 맞는 것이 얼마나 되는지를 파악합니다. 그리고 재현율은 한 클래스에서 모델이 예측한것이 얼마나 되는지입니다. 이 각각의 지표의 성능이 모두 우수해야 모델의 예측이 편향되지 않으면서도 정확하게 예측을 하고 있다라고 평가할 수 있습니다.

혼동행렬: 해당 행렬을 통해서 정밀도와 재현율의 결과를 인간이 보기 쉽게 해석할 수 있습니다.

F1 score: 모델의 정확도와 재현율의 조화 평균입니다. 클래스 불균형이 일어나기 쉬운 모델에서 적용할 수 있는 중요한 지표입니다. 특히 우리가 만든 모델의 경우 클래스 불균형 문제가 크게 발생하기 때문에 이러한 지표를 통해 성능을 분석하여야 합니다.

ROC AUC: 모델의 전반적인 성능을 평가하는데 매우 유용한 지표입니다. 1에 가까울수록 분류 성능이 좋다고 생각할 수 있습니다.

```
# 클래스별 정확도, 정밀도, 재현율 계산
for i in range(3):
    class_indices = true_labels == i
    class_predictions = predicted_classes[class_indices]
    class_true_labels = true_labels[class_indices]

    accuracy = accuracy_score(class_true_labels, class_predictions)
    precision = precision_score(class_true_labels, class_predictions, average='weighted', zero_division=1)
    recall = recall_score(class_true_labels, class_predictions, average='weighted', zero_division=1)

    print(f"Class {i}:")
    print(f" Accuracy: {accuracy:.4f}")
    print(f" Precision: {precision:.4f}")
    print(f" Recall: {recall:.4f}")

# F1-score 계산
f1 = f1_score(true_labels, predicted_classes, average='weighted')
print(f"Overall F1-score: {f1:.4f}")

# Apply softmax to convert logits to probabilities
probabilities = softmax(predictions, axis=1)

# ROC-AUC 계산 (다중 클래스의 경우 'macro' averaging 사용)
roc_auc = roc_auc_score(true_labels, probabilities, multi_class='ovr', average='macro')
print(f"Overall ROC-AUC: {roc_auc:.4f}")


# Confusion Matrix 출력
print("\nConfusion Matrix:")
print(confusion_matrix(true_labels, predicted_classes))
```

	0	1	2
0	405	34	7
1	48	307	60
2	18	70	364

```
Class 0:
  Accuracy: 0.8980
  Recall: 0.8980
Class 1:
  Accuracy: 0.7241
  Recall: 0.7241
Class 2:
  Accuracy: 0.8000
  Recall: 0.8000
Overall F1-score: 0.8213
Overall ROC-AUC: 0.9555
```

5.5 모델 비교과정

<BERT>	<BERT>	<CLOVA	CLOVA
<한국+미국 학습 모델>	<미국 데이터 학습 모델>	<한국+ 미국 뉴스 학습 모델>	<미국 뉴스 학습 모델>



<BERT>

<BERT>

<CLOVA >

<CLOVA>

<한국+미국 학습 모델>

<미국 데이터 학습 모델>

<한국+ 미국 뉴스 학습 모델>

<미국 뉴스 학습 모델>

Class accuracy: 정확도

```
Class 0:
  Accuracy: 0.8980
  Recall: 0.8980
Class 1:
  Accuracy: 0.7241
  Recall: 0.7241
Class 2:
  Accuracy: 0.8000
  Recall: 0.8000
Overall F1-score: 0.8213
Overall ROC-AUC: 0.9555
```




```
Class 0:
  Accuracy: 0.9206
  Recall: 0.9206
Class 1:
  Accuracy: 0.7086
  Recall: 0.7086
Class 2:
  Accuracy: 0.8754
  Recall: 0.8754
Overall F1-score: 0.8521
Overall ROC-AUC: 0.9611
```

Combine model

```
Precision (macro): 0.85
ROC AUC (macro): 0.84
F1-score (macro): 0.77
Cohen's Kappa: 0.74
Accuracy: 81.57%
```

Usa model

```
Precision (macro): 0.85
ROC AUC (macro): 0.84
F1-score (macro): 0.77
Cohen's Kappa: 0.73
Accuracy: 80.75%
```



```
Training...

Average training loss: 0.60
Training epoch took: 0:01:18

Running Validation...
Accuracy: 0.81
Validation loss: 0.49
Validation took: 0:00:07
Best model found and saved.
```

```
===== Epoch 1 / 4 =====
Training...

Average training loss: 0.57
Training epoch took: 0:00:56

Running Validation...
Accuracy: 0.84
Validation loss: 0.42
Validation took: 0:00:05
Best model found and saved.
```

저희가 사용한 모델은 두가지를 사용하였습니다. BERT 모델과 NAVER STUDIO 모델 두가지입니다. 각 모델 내에서 미국 뉴스 데이터 모델과 미국 + 한국 뉴스 데이터 모델을 만들었습니다. 각 모델간에 수치비교를 해보면 BERT는 USA모델이 좀더 F1 score가 좋게 나왔고, CLOVA의 경우 0.77로 동일하지만 정확도 측면에서 미국 + 한국 뉴스 데이터 모델이 좀 더 우수한 성능을 보였기 때문에 각각의 모델을 선택을 하게 되었습니다. 그리고 이 모델로부터 7가지 지표에 뉴스 감정분석화 후에 z-score로 표현한 점수가 아래 탭에서 이어집니다.


6. 뉴스 분석 결과 및 점수화

date	negative 0	neutral 1	positive 2	news_score_com	usa	informative(ex)	negative 0	neutral 1	positive 2
2024-06-17	24	71	16	6.03	5.32	1	37	56	17
2024-06-18	12	42	53	8.99	9.11	0	14	36	57
2024-06-19	10	53	58	9.08	9.48	1	11	43	66
2024-06-20	12	52	41	8.30	8.48	0	15	43	47
2024-06-21	33	36	28	6.16	6.03	0	38	28	31
2024-06-22	1	7	4	8.13	8.45	2	1	5	4
2024-06-23	7	13	3	5.37	5.32	1	8	10	4
2024-06-24	51	51	10	4.12	3.57	1	62	37	12
2024-06-25	4	59	45	8.97	9.15	0	6	52	50
2024-06-26	15	57	33	7.61	7.38	2	22	45	36
2024-06-27	37	44	19	5.33	4.73	1	49	28	22
2024-06-28	11	53	17	6.98	7.22	0	12	48	21
2024-06-29	1	5	1	6.50	7.43	0	1	4	2
2024-06-30	3	11	4	6.86	8.31	0	3	7	8
				news_score_com	usa				
		n		6.03	5.32	ng		12.5점 기준	
		p		8.99	9.11	p			
		p		9.08	9.48	p			
		p		8.30	8.48	p			
		n		6.16	6.03	n			
		p		8.13	8.45	p			
		ng		5.37	5.32	ng			
		ng		4.12	3.57	ng			
		p		8.97	9.15	p			
		p		7.61	7.38	p			
		ng		5.33	4.73	ng			
		p		6.98	7.22	p			
		n		6.50	7.43	p			
		n		6.86	8.31	p			

뉴스 분석에서는 빅카인즈에서 제공하는 경제 키워드를 바탕으로 뉴스 데이터를 예측하고 추가로 코스피, 코스피200, 채권 데이터 데이터를 수집하여 각각의 뉴스 데이터를 수집하였습니다. 이때 각각의 뉴스 데이터로부터 모델이 예측한 결과를 일자별로 평균을 냈고 각각의 점수 산출 방식은 토탈 뉴스 점수 12.5에서 키워드 검색 데이터와 와 한국 증시 키워드에 분석 결과에 6.25씩 부과하여 1대1로 점수화를 진행하였습니다. 위 결과는 2주간의 데이터 분석 결과이고 해당 모델은 naver studio 한국+미국(종합) 뉴스 모델과 미국 뉴스 모델에 대해서 분석한 결과치 입니다. 각 모델이 산출한 결과를 살펴보면 종합 뉴스 모델은 좀 더 안정적인 분석이 있는 반면 상대적으로 미국 뉴스 모델의 경우 좀 더 과해석하는 경향이 있는 것으로 보입니다.


이러한 분석과정을 실제 공포 탐욕 지수에 적용하여 점수화한 그래프를 보겠습니다.

이 그래프를 보면 전체적으로 미국_BERT모델이 NAVER모델에 비해서 낮게 보이는 양상을 보이고 있습니다.



<BERT모델 vs NAVER 모델>


우측 그래프의 경우 BERT 모델과 KOSPI 모델의 추이를 동시에 비교한 것입니다.



<KOSPI와 공포탐욕지수 비교>


종합적으로 보자면 각 모델간의 편향이 되어있기 때문에 모델각각이 약간의 감정 차이가 있다고 결론을 내릴 수 있습니다. 그리고 아래 그래프를 보면서 최종 공포 탐욕 지수가 KOSPI125일 추이와 유사하게 따라가고 있음을 알 수 있습니다.

7. XAI-공포 탐욕 지수 예상 활용 방안



기존의 공포탐욕 지수는 정량적 수치로 표현이 되어있고 이런 수치로 표현된 것에 공포면 매수, 탐욕이면 매도와 같은 알고리즘적 투자 방식을 제안하였습니다. 하지만 이러한 투자에는 확실한 그건가 있어야하며 오랫동안 투자자들에게 충분한 설명없이 뇌동매매를 만들 게 하였습니다. 따라서 투자자들에게 더욱 포지션에 대해서 확신이 아닌 의문점을 남겼습니다. 따라서 저희가 제공하는 XAI-공포 탐욕 지수는 이러한 해석적 불만을 인지하고 이를 해결할 수 있는 서비스를 제안할 수 있습니다.

한국형 공포 탐욕지수는 여러가지 활용이 가능합니다. 기존 공포 탐욕 지수는 투자자들의 포지션에 설정에 대해 좋은 지표가 되었습니다. 투자심리가 공포로 위치해 있을 때 매수 포지션, 탐욕에 위치했을 때 매도 포지션을 잡았습니다. 따라서 해당 공포탐욕지수를 우측과같이 지원을 해준다면 투자자 개인이 어떤 포지션을 잡아야할지에 대해 큰 도움을 줄 것으로 예상 됩니다.



- 미래에셋 어플 자체 코스피 지수
 - 공포지수와 비교하여 분석할 인사이트 제공
- AI 분석 코스피 공포 지수 지표제공
 - 종합된 데이터를 하루하루 갱신
 - 고객은 이 지표를 보고 시장 파악 가능

기존 공포 탐욕에 비해 저희가 만든 XAI 공포탐욕지수의 경우 뉴스 기사를 분석한 결과를 포함한 지수이기에 투자자의 심리를 보다 더 깊이있게 담은 수치입니다. 또한 기존의 공포탐욕이 수치만을 알려주는 것에 그치지 않고 수치에 대한 근거를 제공할 수 있는 뉴스 데이터를 투자자에게 요약하여 설명한다는 큰 장점이 있습니다.

코스피 등락의 이유를 서술해주는 AI →



- 현재 증시에 대한 인사이트 제공
 - 최근 시장상황을 파악하지 못한 고객을 위한 기능
 - 데이터 분석을 통한 원인 분석

포트폴리오영역에서 포지션을 잡는 것은 매우 중요한 영역입니다. XAI 공포탐욕지수는 이러한 영역에 아주 큰 도움을 줄 수 있는 데요. 저희가 만든 지수를 토대로 어떻게 포트폴리오를 구성해야 하는지 지원해 줄 수 있습니다. 또한 어떠한 이슈로 포트폴리오를 제작하게 되었는지에 대한 부분도 잘 설명해 줄 수 있겠습니다.



- 시장상황에 맞춘 포트폴리오 제공
 - 채권, 금, 주가, 공포지수를 분석
 - 데이터를 분석하여 포트폴리오 자산 분배 추천

7.1 서비스 예상 시나리오

저희가 만든 XAI - 공포탐욕지수 서비스의 시나리오는 다음과 같습니다. 투자자들이 장이 시작하기 전에 KB국민은행의 어플리케이션을 엽니다. 기존에는 본인이 관심이 있었던 주식과 관련된 차트 혹은 KOSPI S&P500과같은 차트만으로 증시를 확인했다면 이제는 위그림들과 같은 공포 탐욕 지수를 통해서 현재 증시 상황을 확인합니다. 하지만 투자자들은 이러한 지표들에 대해서 이유에 대해서 궁금할 것입니다. 기존 방식은 뉴스를 열어 확인하거나 네이버 뉴스기사, 각 종목별 뉴스기사 혹은 AI추천하는 레포트를 통해서 확인해야했습니다. 이런 매체를 통해 현재 수치에 대한 근거를 찾아내고 판단의 근거를 찾아내곤 했습니다. 하지만 아쉽게도 이런 수치와 이유분석간의 간극은 너무 컸습니다. 기존 투자자들은 해당 수치와 뉴스, 전문가의 분석의 연결까지 많은 시간이 소요되곤 했습니다. 따라서 저희의 XAI를 이용한다면 현재 증시상황을 종합한 수치를 봄과 동시에 해당 수치의 이유를 AI가 뉴스 기사를 선별하여 설명해주는 서비스를 제공하면서 증시에 대한 이유를 살펴볼 수 있습니다.

이러한 시나리오를 거치게 된다면 KB국민은행 어플리케이션을 이용하는 투자자들은 공포탐욕지수와 뉴스 기사를 확인하면서 해당 사실에 대한 전문가의 분석을 요구할 것이며 이러한 요구에 응하는 KB국민은행 유튜브를 자동으로 연결하여 자세하게 확인할 수 있을 것입니다. 이처럼 저희가 제공하는 XAI서비스는 투자자들의 증시 상황에 대한 근거를 제공해주는 부가 서비스로써 작용을 할 것이며 이러한 서비스가 이어지면 KB국민은행에 대한 신뢰도가 상승하며 증권앱 이용수가 상당히 증가할 것으로 예상할 수 있습니다.